

PROYECTO 1

Análisis Exploratorio de Datos de Inventario

Autor: Jonathan Monroy Arredondo

Perfil: Analista de Datos Junior

Herramientas utilizadas: Python, Pandas, Matplotlib y Jupyter Notebook

Descripción

Este proyecto presenta un análisis exploratorio de una base de datos de inventario con el propósito de identificar la distribución de categorías, productos más frecuentes, calidad de los datos y generar hallazgos que apoyen la toma de decisiones.

1. Carga y exploración de los datos

En esta sección se realiza la carga de la base de datos y una exploración inicial de su estructura.

El objetivo es conocer la cantidad de registros, las variables disponibles y las características principales del conjunto de datos antes de realizar el proceso de limpieza y análisis.

Importación de librerías

Se utiliza Python junto con la biblioteca Pandas para cargar, organizar y analizar los datos.

2. Limpieza y calidad de los datos

En esta etapa se verifica la calidad de la información disponible en la base de datos.

Se revisan posibles valores nulos, registros duplicados y la estructura de las variables con el objetivo de garantizar que los datos sean confiables para el análisis exploratorio.

3. Análisis Exploratorio de Datos (EDA)

En esta sección se realiza un análisis exploratorio de la información para identificar patrones, tendencias y características relevantes del conjunto de datos.

Se analizará la distribución de los productos por categoría y se identificarán las categorías y productos con mayor frecuencia.

El análisis permitirá transformar los datos en información útil para la interpretación y toma de decisiones.

```
In [138... import pandas as pd
df = pd.read_excel("dataset_productos_categorias.xlsx")
```

```
In [125... df["Categoría"].value_counts()
```

```
Out[125... Categoría
Perifericos      508
Computadores     225
Almacenamiento   89
Componentes      70
Impresión        59
Redes            49
Name: count, dtype: int64
```

4. Visualizaciones

Las visualizaciones permiten representar de manera gráfica los principales resultados obtenidos durante el análisis exploratorio.


A continuación se presentan gráficos que facilitan la identificación de patrones y la comparación entre las diferentes categorías y productos del inventario.

4.1 Distribución de productos por categoría

El siguiente gráfico muestra la cantidad de registros pertenecientes a cada categoría del conjunto de datos.


```
In [139... df["Categoría"].value_counts().plot(
    kind="bar",
    title="Cantidad de productos por categoría",
    xlabel="Categoría",
    ylabel="Cantidad"
)
```

```
Out[139... <Axes: title={'center': 'Cantidad de productos por categoría'}, xlabel='Categorí
a', ylabel='Cantidad'>
```



```
In [83]: ax = df["Categoría"].value_counts().plot(
    kind="bar",
    title="Cantidad de productos por categoría",
    xlabel="Categoría",
    ylabel="Cantidad de productos"
)

ax.bar_label(ax.containers[0]);
```




```
In [84]: porcentajes = df["Categoría"].value_counts(normalize=True) * 100  
  
porcentajes
```

```
Out[84]: Categoría  
Perifericos      50.8  
Computadores     22.5  
Almacenamiento   8.9  
Componentes      7.0  
Impresión        5.9  
Redes            4.9  
Name: proportion, dtype: float64
```

```
In [85]: porcentajes = df["Categoría"].value_counts()  
  
porcentajes.plot(  
    kind="pie",  
    autopct="%1.1f%%",  
    title="Distribución de productos por categoría"  
)
```

```
Out[85]: <Axes: title={'center': 'Distribución de productos por categoría'}, ylabel='count'>
```




```
In [86]: productos = df["Producto"].value_counts().head(10)
```

productos


```
Out[86]: Producto
Teclado      171
Mouse        170
Laptop       136
Monitor      129
PC Escritorio 89
Disco SSD    89
Memoria RAM  70
Impresora    59
Router       49
Cámara Web   38
Name: count, dtype: int64
```

```
In [87]: productos.plot(
    kind="bar",
    title="Top 10 productos más frecuentes",
    xlabel="Producto",
    ylabel="Cantidad"
)
```

```
Out[87]: <Axes: title={'center': 'Top 10 productos más frecuentes'}, xlabel='Producto', ylabel='Cantidad'>
```



```
In [88]: ax = productos.plot(  
    kind="bar",  
    title="Top 10 productos más frecuentes",  
    xlabel="Producto",  
    ylabel="Cantidad"  
)  
  
ax.bar_label(ax.containers[0]);
```



```
In [89]: df["Producto"]
```

```
Out[89]: 0      Impresora
1       Mouse
2       Laptop
3   Cámara Web
4       Teclado
...
995      Monitor
996      Laptop
997   Memoria RAM
998   Memoria RAM
999      Monitor
Name: Producto, Length: 1000, dtype: object
```


```
In [90]: productos = df["Producto"].value_counts().head(10)

productos
```

```
Out[90]: Producto
Teclado      171
Mouse        170
Laptop       136
Monitor      129
PC Escritorio 89
Disco SSD    89
Memoria RAM  70
Impresora    59
Router       49
Cámara Web   38
Name: count, dtype: int64
```

```
In [91]: ax = productos.plot(
        kind="bar",
        title="Top 10 productos más frecuentes",
        xlabel="Producto",
        ylabel="Cantidad de productos"
    )

ax.bar_label(ax.containers[0]);
```



```
In [92]: df["Producto"].value_counts()
```



```
Out[92]: Producto
          Teclado      171
          Mouse       170
          Laptop      136
          Monitor     129
          PC Escritorio 89
          Disco SSD   89
          Memoria RAM  70
          Impresora    59
          Router       49
          Cámara Web   38
          Name: count, dtype: int64
```

```
In [93]: df.head()
```

```
Out[93]:
```

	ID	Producto	Categoría
0	1	Impresora	Impresión
1	2	Mouse	Perifericos
2	3	Laptop	Computadores
3	4	Cámara Web	Perifericos
4	5	Teclado	Perifericos

```
In [94]: productos = df["Producto"].value_counts().head(10)

productos
```

```
Out[94]: Producto
          Teclado      171
          Mouse       170
          Laptop      136
          Monitor     129
          PC Escritorio 89
          Disco SSD   89
          Memoria RAM  70
          Impresora    59
          Router       49
          Cámara Web   38
          Name: count, dtype: int64
```

```
In [95]: porcentaje_productos = df["Producto"].value_counts(normalize=True) * 100

porcentaje_productos.head(10)
```

```
Out[95]: Producto
Teclado      17.1
Mouse        17.0
Laptop       13.6
Monitor      12.9
PC Escritorio 8.9
Disco SSD     8.9
Memoria RAM   7.0
Impresora     5.9
Router        4.9
Cámara Web   3.8
Name: proportion, dtype: float64
```

```
In [96]: producto_mas_frecuente = df["Producto"].value_counts().iloc[0]
total_productos = len(df)

porcentaje = (producto_mas_frecuente / total_productos) * 100

porcentaje
```

```
Out[96]: np.float64(17.1)
```

```
In [97]: producto_top_categoria = (
    df.groupby("Categoría")["Producto"]
    .value_counts()
    .groupby(level=0)
    .head(1)
)

producto_top_categoria
```


```
Out[97]: Categoría    Producto
Almacenamiento  Disco SSD      89
Componentes     Memoria RAM    70
Computadores    Laptop        136
Impresión       Impresora      59
Perifericos     Teclado        171
Redes           Router         49
Name: count, dtype: int64
```

```
In [98]: df.groupby("Categoría")["Producto"].value_counts()
```

```
Out[98]: Categoría    Producto
Almacenamiento  Disco SSD      89
Componentes     Memoria RAM    70
Computadores    Laptop        136
                 PC Escritorio  89
Impresión       Impresora      59
Perifericos     Teclado        171
                 Mouse         170
                 Monitor        129
                 Cámara Web     38
Redes           Router         49
Name: count, dtype: int64
```


```
In [99]: producto_top_categoria.plot(  
        kind="bar",  
        title="Producto más frecuente por categoría",  
        xlabel="Categoría - Producto",  
        ylabel="Cantidad"  
    )
```

```
Out[99]: <Axes: title={'center': 'Producto más frecuente por categoría'}, xlabel='Categoría  
- Producto', ylabel='Cantidad'>
```



```
In [100... top_categoria = producto_top_categoria.reset_index()  
  
top_categoria["Etiqueta"] = (  
    top_categoria["Categoría"] + " - " + top_categoria["Producto"]  
)  
  
ax = top_categoria.plot()
```

```
x="Etiqueta",  
y="count",  
kind="bar",  
title="Producto más frecuente por categoría",  
xlabel="Categoría - Producto",  
ylabel="Cantidad",  
legend=False  
)  
  
ax.bar_label(ax.containers[0]);
```



```
In [101... df.isnull().sum()
```

```
Out[101... ID          0  
Producto      0  
Categoría     0  
dtype: int64
```

```
In [102... df.duplicated().sum()
```

```
Out[102... np.int64(0)
```

```
In [103... df["Producto"].unique()
```

```
Out[103... array(['Impresora', 'Mouse', 'Laptop', 'Cámara Web', 'Teclado', 'Monitor',  
      'Router', 'PC Escritorio', 'Disco SSD', 'Memoria RAM'],  
      dtype=object)
```

```
In [104... df["Categoría"].unique()
```

```
Out[104... array(['Impresión', 'Perifericos', 'Computadores', 'Redes',  
      'Almacenamiento', 'Componentes'], dtype=object)
```

```
In [105... print("Productos diferentes:", df["Producto"].nunique())  
print("Categorías diferentes:", df["Categoría"].nunique())
```

Productos diferentes: 10

Categorías diferentes: 6

```
In [106... df.groupby("Producto")["Categoría"].nunique()
```

```
Out[106... Producto  
Cámara Web      1  
Disco SSD       1  
Impresora       1  
Laptop          1  
Memoria RAM     1  
Monitor         1  
Mouse           1  
PC Escritorio   1  
Router          1  
Teclado         1  
Name: Categoría, dtype: int64
```

```
In [107... df["Producto"].value_counts()
```

```
Out[107... Producto  
Teclado         171  
Mouse           170  
Laptop          136  
Monitor         129  
PC Escritorio   89  
Disco SSD       89  
Memoria RAM     70  
Impresora       59  
Router          49  
Cámara Web      38  
Name: count, dtype: int64
```

```
In [108... (df["Producto"].value_counts(normalize=True) * 100).round(2)
```

```
Out[108...] Producto
Teclado          17.1
Mouse            17.0
Laptop           13.6
Monitor          12.9
PC Escritorio    8.9
Disco SSD        8.9
Memoria RAM      7.0
Impresora        5.9
Router           4.9
Cámara Web       3.8
Name: proportion, dtype: float64
```

```
In [109...] total_registros = len(df)

numero_categorias = df["Categoría"].nunique()

producto_top = df["Producto"].value_counts().idxmax()
cantidad_producto_top = df["Producto"].value_counts().max()

categoria_top = df["Categoría"].value_counts().idxmax()
cantidad_categoria_top = df["Categoría"].value_counts().max()

print("==== DASHBOARD DE PRODUCTOS =====")
print("Total de registros:", total_registros)
print("Número de categorías:", numero_categorias)
print("Producto más frecuente:", producto_top, "-", cantidad_producto_top)
print("Categoría dominante:", categoria_top, "-", cantidad_categoria_top)


==== DASHBOARD DE PRODUCTOS =====
Total de registros: 1000
Número de categorías: 6
Producto más frecuente: Teclado - 171
Categoría dominante: Perifericos - 508
```

```
In [110...] conteo_categorias = df["Categoría"].value_counts()

ax = conteo_categorias.plot(
    kind="bar",
    figsize=(10, 5),
    title="Distribución de productos por categoría"
)

ax.set_xlabel("Categoría")
ax.set_ylabel("Cantidad de registros")
ax.bar_label(ax.containers[0])
```

```
Out[110...] [Text(0, 0, '508'),
Text(0, 0, '225'),
Text(0, 0, '89'),
Text(0, 0, '70'),
Text(0, 0, '59'),
Text(0, 0, '49')]
```




```
In [111...] top_productos = df["Producto"].value_counts().head(10)

ax = top_productos.plot(
    kind="bar",
    figsize=(10, 5),
    title="Top 10 productos más frecuentes"
)

ax.set_xlabel("Producto")
ax.set_ylabel("Cantidad de registros")
ax.bar_label(ax.containers[0])
```

```
Out[111...] [Text(0, 0, '171'),
Text(0, 0, '170'),
Text(0, 0, '136'),
Text(0, 0, '129'),
Text(0, 0, '89'),
Text(0, 0, '89'),
Text(0, 0, '70'),
Text(0, 0, '59'),
Text(0, 0, '49'),
Text(0, 0, '38')]
```



In [112...

```
import matplotlib.pyplot as plt

total_registros = len(df)

numero_categorias = df["Categoría"].nunique()

producto_top = df["Producto"].value_counts().idxmax()
cantidad_producto_top = df["Producto"].value_counts().max()

categoria_top = df["Categoría"].value_counts().idxmax()
cantidad_categoria_top = df["Categoría"].value_counts().max()

categorias = df["Categoría"].value_counts()
productos = df["Producto"].value_counts().head(10)

fig = plt.figure(figsize=(16, 10))

fig.suptitle(
    "Dashboard de Inventario - Análisis Exploratorio de Datos",
    fontsize=20,
    fontweight="bold"
)

kpis = [
    ("TOTAL REGISTROS", f"{total_registros:}"),
    ("CATEGORÍAS", f"{numero_categorias}"),
    ("PRODUCTO MÁS FRECUENTE", f"{producto_top}\n{cantidad_producto_top} registros"),
    ("CATEGORÍA DOMINANTE", f"{categoria_top}\n{cantidad_categoria_top} registros")
]

posiciones = [
```



```
(0.05, 0.80),
(0.28, 0.80),
(0.51, 0.80),
(0.74, 0.80)
]

for (titulo, valor), (x, y) in zip(kpis, posiciones):

    ax_kpi = fig.add_axes([x, y, 0.20, 0.12])

    ax_kpi.set_xticks([])
    ax_kpi.set_yticks([])

    for spine in ax_kpi.spines.values():
        spine.set_visible(True)

    ax_kpi.text(
        0.5, 0.70,
        titulo,
        ha="center",
        va="center",
        fontsize=10,
        fontweight="bold"
    )

    ax_kpi.text(
        0.5, 0.35,
        valor,
        ha="center",
        va="center",
        fontsize=15,
        fontweight="bold"
    )

ax1 = fig.add_axes([0.07, 0.43, 0.42, 0.28])

categorias.plot(
    kind="bar",
    ax=ax1
)

ax1.set_title(
    "Distribución de productos por categoría",
    fontsize=13,
    fontweight="bold"
)

ax1.set_xlabel("Categoría")
ax1.set_ylabel("Cantidad")


ax1.bar_label(ax1.containers[0])

ax1.tick_params(axis="x", rotation=35)

ax2 = fig.add_axes([0.56, 0.43, 0.36, 0.28])
```

```
categorias.plot(  
    kind="pie",  
    autopct="%1.1f%%",  
    ax=ax2  
)  
  
ax2.set_title(  
    "Participación por categoría",  
    fontsize=13,  
    fontweight="bold"  
)  
  
ax2.set_ylabel("")  
  
ax3 = fig.add_axes([0.15, 0.07, 0.70, 0.25])  
  
productos.plot(  
    kind="bar",  
    ax=ax3  
)  
  
ax3.set_title(  
    "Top 10 productos más frecuentes",  
    fontsize=13,  
    fontweight="bold"  
)  
  
ax3.set_xlabel("Producto")  
ax3.set_ylabel("Cantidad")  
  
ax3.bar_label(ax3.containers[0])  
  
ax3.tick_params(axis="x", rotation=35)  
  
plt.savefig(  
    "dashboard_inventario.png",  
    dpi=300,  
    bbox_inches="tight"  
)
```

Dashboard de Inventario - Análisis Exploratorio de Datos



In [113...

```
plt.savefig(
    "dashboard_inventario.png",
    dpi=300,
    bbox_inches="tight"
)

plt.show()
```

<Figure size 640x480 with 0 Axes>

plt.show()

5. Principales hallazgos

A partir del análisis exploratorio realizado se identificaron los siguientes hallazgos:

- La base de datos contiene **1.000 registros**.
- El conjunto de datos está compuesto por **6 categorías**.
- La categoría **Periféricos** es la más representativa, con **508 registros**, equivalentes al **50,8 %** del total.
- El producto con mayor frecuencia es **Teclado**, con **171 registros**, equivalente al **17,1 %** del total.
- La categoría Periféricos concentra más de la mitad de los registros analizados.
- No se encontraron **valores nulos** en la información.

- No se identificaron **registros duplicados**.

Estos resultados permiten identificar una concentración importante del inventario en la categoría de periféricos y proporcionan una visión general de la composición del conjunto de datos.

6. Conclusiones

El análisis exploratorio permitió comprender la composición y distribución del inventario a partir de 1.000 registros y 6 categorías de productos.

Los resultados muestran que **Periféricos** es la categoría con mayor participación, representando el **50,8 %** de los registros. Dentro de los productos analizados, **Teclado** y **Mouse** presentan las mayores frecuencias, con 171 y 170 registros respectivamente.

En cuanto a la calidad de los datos, no se encontraron valores nulos ni registros duplicados, lo que indica que la base de datos presenta una estructura consistente y adecuada para realizar análisis posteriores.

En conclusión, el análisis permitió transformar los datos del inventario en información útil para identificar los productos y categorías con mayor presencia. Estos resultados pueden servir como apoyo para la planificación de inventario, priorización de productos y toma de decisiones.

Resultado final del proyecto

Herramientas: Python · Pandas · Matplotlib · Jupyter Notebook

Tipo de análisis: Análisis Exploratorio de Datos (EDA)

Registros analizados: 1.000

Categorías: 6

Categoría dominante: Periféricos

Producto más frecuente: Teclado

```
In [1]: import matplotlib.pyplot as plt

registros = 1000
categorias = 6
categoria_dominante = "Periféricos"
cantidad_categoria = 508
producto_mas_frecuente = "Teclado"
cantidad_producto = 171
```

```
porcentaje_categoria = cantidad_categoria / registros * 100
porcentaje_producto = cantidad_producto / registros * 100

fig, ax = plt.subplots(figsize=(13, 4))

ax.axis("off")

ax.text(
    0.5, 0.92,
    "RESUMEN EJECUTIVO DEL ANÁLISIS",
    ha="center",
    va="center",
    fontsize=22,
    fontweight="bold"
)

tarjetas = [
    (0.125, f"{registros:,}", "REGISTROS ANALIZADOS"),
    (0.375, str(categorias), "CATEGORÍAS"),
    (0.625, categoria_dominante, f"{cantidad_categoria} REGISTROS · {porcentaje_cat"),
    (0.875, producto_mas_frecuente, f"{cantidad_producto} REGISTROS · {porcentaje_p
]

for x, valor, etiqueta in tarjetas:

    ax.text(
        x, 0.58,
        valor,
        ha="center",
        va="center",
        fontsize=20,
        fontweight="bold"
    )

    ax.text(
        x, 0.35,
        etiqueta,
        ha="center",
        va="center",
        fontsize=9
    )

plt.tight_layout()
plt.show()
```

RESUMEN EJECUTIVO DEL ANÁLISIS

1,000

6

Periféricos

Teclado

REGISTROS ANALIZADOS

CATEGORIAS

508 REGISTROS · 50.8%

171 REGISTROS · 17.1%

In []: